

O corpus do projeto: Clubes Tradicionais de Futebol da Baixada Santista

Grupo APPA

2 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Projeto Integrador III — Motor de Busca | Prof. Dr.
João Paulo Ferreira de Mello

Arthur Galvão

Pedro Henrique

Ailana

Repositório: <https://github.com/kyl8/pi3>

1 Introdução

O presente projeto tem como tema a recuperação de informação histórica e patrimonial dos três clubes centenários de futebol da Baixada Santista: Santos Futebol Clube, Associação Atlética Portuguesa e Jabaquara Atlético Clube. A região de Santos possui uma das trajetórias futebolísticas mais expressivas do Brasil, abrigando agremiações pioneiras que participaram ativamente da estruturação do esporte paulista no início do século XX e influenciaram a cultura litorânea.

O motor de busca proposto destina-se a pesquisadores de história esportiva, estudantes de ciência de dados, jornalistas e torcedores que buscam consultar dados objetivos sobre a memória esportiva regional. Em recuperação de informação, a modelagem busca satisfazer a necessidade de informação do usuário de forma precisa, sem exigir que a pessoa conheça antecipadamente a terminologia técnica exata da base (MANNING; RAGHAVAN; SCHÜTZ, 2008, cap. 1). Com base nesse princípio, o sistema foi concebido para atender a três necessidades centrais:

1. **Fundação, origens e cores:** identificar a data e o contexto histórico de fundação dos clubes, assim como suas cores e símbolos representativos;
2. **Estádios e patrimônio físico:** localizar dados sobre os estádios das equipes (Vila Belmiro, Ulrico Mursa e Caneleira) e sua infraestrutura patrimonial;
3. **Títulos e rivalidades regionais:** consultar conquistas marcantes, rivalidades históricas e confrontos locais, a exemplo do Clássico das Praias.

Este relatório formaliza a Entrega 1 do projeto: documenta a fonte e a licença dos dados, detalha as etapas de coleta automatizada, reporta as dificuldades operacionais encontradas e apresenta a defesa empírica da suficiência do corpus coletado.

2 A fonte e o documento

O corpus foi obtido a partir da Wikipédia em língua portuguesa (WIKIPEDIA, 2026), sob licença livre Creative Commons Atribuição-CompartilhaIgual 4.0 Internacional (CC BY-SA 4.0), com coleta efetuada em 2026. Foram extraídas três páginas principais: **Santos Futebol Clube**, **Associação Atlética Portuguesa (Santos)** e **Jabaquara Atlético Clube**. No total, o acervo consolidado reúne $N = 141$ documentos extraídos de 3 páginas enciclopédicas.

A unidade de documento adotada é o *parágrafo textual* ($< p >$). A escolha do parágrafo fundamenta-se na granularidade de recuperação: adotar o artigo enciclopédico inteiro como um único documento implicaria que uma busca sobre a capacidade da Vila Belmiro retornaria a página completa de dezenas de páginas do Santos FC, exigindo navegação manual exaustiva do usuário. Por outro lado, a segmentação por frases isoladas produziria fragmentos com contexto semântico insuficiente. O parágrafo enciclopédico configura, portanto, a menor unidade autossuficiente capaz de responder integralmente a uma consulta específica.

A adoção da Wikipédia como fonte deve-se à qualidade da redação colaborativa, à perenidade dos fatos históricos relatados e à acessibilidade de sua estrutura textual. Como alternativa, avaliou-se inicialmente a extração a partir de sites institucionais oficiais e páginas de torcidas organizadas. Essa opção foi descartada por apresentar formatações instáveis, conteúdo promocional de vendas de ingressos e ausência de licença aberta uniforme para reuso de dados.

3 Como o corpus foi obtido

A coleta foi estruturada em script computacional reprodutível em linguagem R, registrado no repositório. O fluxo operou em cinco etapas sequenciais:

1. **Requisição e parsing:** obtenção do código HTML das três páginas selecionadas na Wikipédia;
2. **Isolamento de parágrafos:** seleção dos nós `<p>` pertencentes ao corpo principal da página enciclopédica;
3. **Sanitização textual:** remoção de tags de hyperlink, eliminação sistemática de notas sobrescritas de rodapé (como [1] ou [nota 2]) e expurgo de caracteres residuais de escape;
4. **Filtragem por tamanho mínimo:** aplicação do limiar de corte de 50 caracteres, eliminando legendas órfãs, linhas de navegação e parágrafos sem densidade informativa;
5. **Serialização:** salvamento dos vetores nomeados de documentos e procedência nos arquivos `docs.rds` e `origem.rds`.

Durante o processo de extração, três desafios operacionais foram contornados:

- **Desambiguação de títulos:** a busca inicial por “Portuguesa” remetia à Associação Portuguesa de Desportos (da capital paulista); foi necessário fixar explicitamente o título Associação Atlética Portuguesa (Santos);
- **Fragmentos residuais:** elementos pertencentes a caixas de navegação lateral (*infoboxes*) foram inicialmente capturados como parágrafos curtos, sendo sanados pelo refinamento do seletor CSS restrito ao corpo textual principal;
- **Disparidade no volume de texto:** a projeção internacional do Santos FC resulta em um artigo substancialmente mais longo do que os dos clubes coirmãos, questão gerenciada na defesa técnica a seguir.

4 Defesa do corpus

A Tabela 1 sumariza o diagnóstico técnico do corpus, acompanhada pela Tabela 2 com a distribuição dos documentos por página.

Tabela 1 – Diagnóstico do corpus

Verificação	Resultado
Tamanho	141 docs de 3 págs.
Tokens/doc	8 a 322 (média 83,6)
Vocabulário	2517 termos (11794 tokens)
Domínio	Santos FC: 107 de 141 (76%)
Suspeitos	7 com menos de 20 tokens; 2 com mais de 300
Sujeira	141 com acento, 141 com pontuação, 135 com dígitos (de 141)

Fonte: Elaborada pelos autores.

Tabela 2 – Documentos por página

Página	Documentos	Tokens (média)
Santos FC	107	91,7
Portuguesa Santista	23	53,3
Jabaquara	11	68,8

Fonte: Elaborada pelos autores.


Tamanho. O corpus conta com 141 documentos, superando a faixa de referência (20 a 60). Essa densidade garante suporte estatístico aos cálculos de matriz termo-documento

e IDF das próximas etapas.

Domínio de página. A Tabela 2 evidencia o predomínio do Santos FC (**Santos** FC: 107 de 141 (76%)), reflexo natural do acervo disponível. A presença de 34 documentos dos demais clubes assegura que o motor recupere dados sobre a história regional integrada.

Comprimento e distribuição. A Figura 1 exibe o perfil unimodal de tokens por parágrafo (média de 83,6), confirmando regularidade estrutural.

Figura 1 – Distribuição de tokens por documento



Fonte: Elaborada pelos autores.

Sujeira e vocabulário. Os dez termos mais frequentes são o, de, a, e, em, do, santos, da, no, na, sendo **santos** o único termo temático no topo. Os demais são palavras gramaticais (*stopwords*), comprovando a necessidade do pré-processamento da Aula 03.

Veredito. O corpus atende plenamente às três necessidades de informação e está pronto e serializado para as etapas subsequentes.

Referências

MANNING, C. D.; RAGHAVAN, P.; SCHÜTZE, H. *Introduction to Information Retrieval*. [S.l.]: Cambridge University Press, 2008.

WIKIPEDIA. *Portal da Wikipédia*. 2026. Disponível em: <<https://pt.wikipedia.org>>.