
Relevância e o Gabarito

Aula 05 — Julgamento, *pooling* e concordância entre juízes

Projeto Integrador III ■ Ciência de Dados

FATEC — Tecnologia em Ciência de Dados

Por que avaliar?

- Já temos vários modelos: booleano, TF-IDF, BM25.
- **Qual é o melhor?** Precisamos medir, não “achar”.
- Para medir, precisamos antes de um **gabarito**.

Princípio

Fixar consultas + julgamentos de relevância e comparar sistemas sobre a **mesma** base.

Sem gabarito, “esse modelo parece melhor” não é resultado — é opinião.

Hoje — Aula 05

De onde vem o gabarito.

- Necessidade $\times$ consulta
- Quem julga, e como
- *Pooling*
- Concordância entre juízes (κ)

Aula 5,5

O que se calcula com ele.

- Precisão, Recall, o “@ k ”
- MAP
- nDCG
- MRR

A ordem importa: vocês vão **construir** o gabarito esta semana e **calcular** sobre ele na próxima.

Antes de medir: o que estamos medindo?

Necessidade de informação

O que a pessoa *queria saber*. Escrita em prosa, uma ou duas frases.

Consulta

As palavras que ela *digitou*. Uma tradução pobre e incompleta da necessidade.

Julga-se a relevância contra a **necessidade**, nunca contra a consulta.

Se julgássemos contra as palavras da consulta, estaríamos medindo casamento léxico — que é exatamente o que o sistema faz. A avaliação seria **circular**.


Quem decide o que é relevante?

- **Uma pessoa.** Não existe fórmula: se existisse, ela seria o motor de busca.
- No **TREC**, avaliadores contratados pelo NIST — um por tópico.
- No **ARQMath**, estudantes de matemática treinados para a tarefa.
- **Neste projeto, são vocês.**

Consequência prática

O gabarito é um **dado** do projeto, versionado no repositório, com o mesmo peso do código. Um gabarito ruim faz um sistema bom parecer ruim — e ninguém descobre.

A ordem obrigatória



Nunca inverte os dois últimos

Se você julgar *depois* de ver o ranking, vai ajustar o gabarito ao sistema sem perceber. O documento que o BM25 trouxe em primeiro começa a parecer relevante.

Preciso julgar um por um?

Sim — e não há atalho honesto.

- Com **8** documentos: 8 julgamentos por consulta. Trivial.
- Com **6.673** documentos e 20 consultas: **133.460** julgamentos. Inviável.

A saída não é automatizar o julgamento — isso destruiria o gabarito. A saída é **julgar menos documentos, escolhidos bem**.

É o método do TREC, e chama-se *pooling*.

Pooling: como funciona

- 1 Rodar **cada modelo** (booleano, TF-IDF, BM25) para **cada consulta**.
- 2 Pegar o **top- k** de cada modelo — tipicamente $k = 10$ ou 20 .
- 3 **Unir e deduplicar** por consulta: essa é a *pool*.
- 4 **Embaralhar** a ordem dentro da *pool*.
- 5 Julgar **só a *pool***. Tudo que ficou de fora é assumido irrelevante.

Por que o passo 4 não é opcional

Se o juiz vê os documentos na ordem do BM25, ele julga com **viés de posição**: o que vem primeiro parece mais relevante. O gabarito passaria a favorecer o BM25 — justamente o modelo que queríamos avaliar.

Pooling: a conta

consultas	20
modelos	3
top- k por modelo	10
documentos por consulta, com repetição	30
após deduplicar (na prática, $\sim 60\%$ únicos)	≈ 18
julgamentos no total	≈ 360
a 20 s cada	≈ 2 horas
divididas entre 4 pessoas	30 min cada

De 133 mil para 360. O *pooling* é o que torna a avaliação possível — e ele não é de graça, como o próximo slide mostra.

O viés, dito com todas as letras

Um documento que **nenhum** modelo recuperou nunca entra na *pool*, logo nunca é julgado, logo é tratado como irrelevante — mesmo que seja ótimo.

- O **recall** calculado fica **superestimado**: o denominador (R) só conta os relevantes que alguém achou.
- Um modelo **novo**, avaliado depois com uma *pool* antiga, é penalizado: os bons documentos que só ele acha não estão no gabarito.
- Quanto **mais modelos** entram na *pool*, menor o viés.

Isso é conhecido e aceito na literatura — mas tem que estar **escrito no relatório**. Limitação declarada é ciência; limitação escondida, não.

Relevância não é sim ou não

grau	significado
2	responde à necessidade
1	fala do assunto sem responder
0	não serve

- O TREC usa 0/1/2; o ARQMath usa 0 a 3. Nós usaremos **0, 1, 2**.
- Para as métricas **binárias** é preciso escolher um **limiar**: “relevante” = grau ≥ 2 .
- O **nDCG** (Aula 5,5) é a única que usa os graus como são.

Mais níveis dão mais informação e mais discordância. Três é um bom compromisso.

O que o guia de julgamento precisa resolver

Duas pessoas só julgam parecido se os **casos de fronteira** estiverem decididos **antes**.

- Documento **correto mas superficial** — menciona a resposta sem explicar.
- Documento correto **no idioma errado**.
- Documento que responde **só a uma parte** da pergunta.
- Documento **excelente** que o usuário **certamente já conhece**.
- Documento **duplicado** ou quase idêntico a outro já julgado.

Formato

Uma página. Uma frase operacional por grau, escrita com o vocabulário do *seu corpus*, mais cinco casos de fronteira já decididos, cada um com a justificativa.

Três colunas essenciais: consulta, documento, grau. Uma linha por julgamento.

consulta	documento	grau	juiz	timestamp
q01	d0142	2	joao	2026-09-15T14:22:31
q01	d0891	0	joao	2026-09-15T14:22:48
q01	d0142	1	maria	2026-09-16T09:03:12

A terceira linha não é erro: é o mesmo item julgado por outra pessoa — o **julgamento duplo**, que vamos usar daqui a três slides. Registrar **quem** e **quando** não é burocracia: é o que permite auditar.

Necessidade de informação

“Quais são os modelos formais que um motor de busca usa para ordenar documentos?”

Consulta digitada: modelo de recuperacao

doc	conteúdo	grau
d2	o modelo de espaco vetorial representa documentos como vetores	2
d3	bm25 e um modelo probabilistico de ranqueamento de texto	2
d1	recuperacao de informacao ordena documentos por relevancia	1
d6	embeddings capturam a semantica de palavras e documentos	1
d4	aprendizado estatistico fundamenta a recuperacao moderna	0
d5, d7, d8	índice invertido / avaliação / ciência de dados	0

É este gabarito que vamos usar na Aula 5,5.

O julgamento em voz alta

- **d2 e d3 (grau 2)**: apresentam um *modelo* — espaço vetorial e BM25. Respondem à pergunta.
- **d1 (grau 1)**: diz *o que é* recuperação de informação, mas não apresenta modelo algum. Contexto útil, não resposta.
- **d6 (grau 1)**: *embeddings* são a base da recuperação densa, mas o texto não diz isso.
- **d4 (grau 0)**: fala de *fundamento*, não de modelo.

O detalhe que interessa

O BM25 colocou d1 em 2º lugar — porque d1 contém a palavra “recuperacao”. Mas d1 não responde à pergunta.

Casamento léxico $\neq$ relevância. É disso que trata o resto do curso.

- Dois avaliadores humanos concordam tipicamente em **70–80%** dos julgamentos.
- Não é desleixo: relevância **tem** componente subjetivo.
- Se o grupo todo julgar itens diferentes, ninguém descobre que estão usando critérios diferentes.

Julgamento duplo

Separe **20% da *pool*** para ser julgada por **duas** pessoas, **sem se consultarem**. Esses itens não servem só para o gabarito — servem para **medir o próprio processo**.

No nosso exemplo: $20\% \text{ de } 360 = 72$ itens julgados em duplicata.
Vamos usar uma amostra de **40** deles para a conta a seguir.

Concordar 77,5% é bom?

Dois juízes julgaram os mesmos 40 itens. Concordaram em **31** deles: $31/40 = 77,5\%$.

O problema

A maior parte dos documentos de uma *pool* é **irrelevante**. Se os dois juízes disserem “0” quase sempre, eles concordam bastante **por acaso** — sem que isso diga nada sobre o critério deles.

A pergunta certa

Quanto da concordância observada está **acima** do que o acaso já explicaria?

Quem responde isso é o κ **de Cohen**.

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

- p_o — concordância **observada**: a fração de itens em que os dois deram a mesma nota.
- p_e — concordância **esperada por acaso**: o que dois juízes obteriam se sortearassem as notas mantendo cada um as suas próprias proporções.

Como ler a fórmula

O **denominador** $1 - p_e$ é o espaço que *sobrava* acima do acaso.

O **numerador** $p_o - p_e$ é quanto desse espaço foi *efetivamente ocupado*.

κ é a **fração aproveitada**. Se $p_o = p_e$, $\kappa = 0$: a concordância foi toda acaso.

A matriz de concordância

```
# 40 itens julgados pelos dois; linhas = juiz A, colunas = juiz B
m <- matrix(c(18, 3, 0,      # A deu 0: B deu 0 em 18, 1 em 3, 2 em 0
              2, 6, 2,      # A deu 1
              0, 2, 7),     # A deu 2
            nrow = 3, byrow = TRUE)
rownames(m) <- paste0("A=", 0:2)
colnames(m) <- paste0("B=", 0:2)
m
```

	B=0	B=1	B=2
A=0	18	3	0
A=1	2	6	2
A=2	0	2	7

A **diagonal** são os acordos: $18 + 6 + 7 = 31$. Fora dela, as discordâncias — e note que nenhuma é extrema (ninguém deu 0 onde o outro deu 2).

```
n <- sum(m)           # 40 itens
po <- sum(diag(m)) / n # OBSERVADA: soma da diagonal sobre o total
po

[1] 0.775

# ESPERADA: produto das marginais, como em um teste qui-quadrado
pe <- sum(rowSums(m) * colSums(m)) / n^2
pe

[1] 0.381875

kappa <- (po - pe) / (1 - pe)
round(kappa, 3)

[1] 0.636
```

Marginais: o juiz A deu (21, 10, 9) e o juiz B deu (20, 11, 9) notas de cada grau.

$$p_o = \frac{18 + 6 + 7}{40} = \frac{31}{40} = 0,775$$

$$p_e = \frac{21 \times 20 + 10 \times 11 + 9 \times 9}{40^2} = \frac{420 + 110 + 81}{1600} = \frac{611}{1600} = 0,382$$

$$\kappa = \frac{0,775 - 0,382}{1 - 0,382} = \frac{0,393}{0,618} = \mathbf{0,636}$$

A concordância bruta era 77,5%. Descontado o acaso, sobra **63,6%**.

Interpretando o κ

κ	leitura	o que fazer
$< 0,4$	fraca	o guia está ambíguo: reescrever e rejulgar
0,4 a 0,6	moderada	aceitável, mas registrar a limitação
$\geq 0,6$	boa	seguir adiante

Por que um κ imperfeito não invalida a comparação

O ruído do gabarito atinge **todos os modelos igualmente**.

Ele atrapalha a leitura do *valor absoluto* (“MAP = 0,83” significa o quê?), mas não a pergunta que realmente importa: **“o BM25 é melhor que o TF-IDF?”**

Comparação é mais robusta que medição absoluta.

Uma decisão que parece prematura — e não é

Na **Aula 09** o gabarito deixa de ser régua e vira **rótulo de treino** de um modelo de *learning to rank*. Treinar e avaliar nas **mesmas** consultas produz melhoria falsa.

- Isso **não tem conserto depois**: se as 20 consultas forem julgadas sem separação, tudo já está contaminado.
- Então decidam **agora**, antes de julgar o primeiro item:

conjunto	consultas	uso
desenvolvimento	q01–q14	ajustar parâmetros, testar ideias, errar
teste	q15–q20	não se olha até o relatório final

Para que serve este gabarito

Vocês constroem uma vez. Ele é usado até a semana 18.

aula	tema	papel do gabarito
06	Rocchio	entrada do algoritmo , não só da métrica
07	recuperação densa	responde “ <i>embeddings</i> batem o BM25?”
08	rerank neural	mede se reordenar o topo melhorou
09	learning to rank	vira rótulo de treino
13	avaliação final	a tabela modelo $\times$ métrica
14	RAG	a recuperação é o teto da qualidade do RAG
16	A/B e <i>interleaving</i>	contraste entre <i>offline</i> e <i>online</i>
17	ética e viés	o gabarito é onde o viés entra

É a peça mais reaproveitada do projeto — e a única que vocês não conseguem refazer às pressas.

Laboratório: montando o experimento

No repositório da aula há o arquivo `PROMPT_LLM_julgamento_relevancia.md`. Ele é um **briefing** para vocês colarem na LLM que usam.

A divisão de trabalho

A LLM **olha para o corpus de vocês e monta o aparato**: analisa os campos, propõe as necessidades de informação, escreve o guia, desenha a *pool*, gera uma página `julgar.html` e os scripts em R.

Vocês fazem o julgamento.

A regra

Se a LLM decidir o que é relevante, vocês estarão medindo a opinião dela sobre o resultado dela. O briefing manda ela **recusar** — e manda vocês **testarem** se ela recusa mesmo.

Tarefa 1 — explicar e explorar o código

Explicar linha a linha os dois *chunks* do κ . Depois, alterar e reportar o efeito:

- o que acontece com κ se os dois juízes derem 0 a 38 dos 40 itens e concordarem em 37?
- construa uma matriz em que $p_o = 0,8$ mas $\kappa < 0,3$;
- o que significa κ **negativo**?

Tarefa 2 — o gabarito do grupo

- ① Escrever **3 necessidades de informação** em prosa, com suas consultas, para o *corpus* de 8 documentos.
- ② Julgar os 8 documentos para cada uma (grau 0/1/2), **antes** de rodar qualquer sistema.
- ③ Comparar com o gabarito de outro grupo e calcular o κ entre vocês.

Próxima aula — 5,5

- Precisão, Recall e o “@*k*”
- MAP, nDCG, MRR
- Tudo calculado sobre o gabarito de hoje

Leitura

- Manning et al., *IIR* — cap. 8
- Baeza-Yates & Ribeiro-Neto — cap. 4
- Voorhees, *The Philosophy of IR Evaluation* (2002)

A ideia para levar

O gabarito é tão importante quanto o modelo — e é **humano**.

Toda métrica de RI é uma opinião sobre *o que o usuário queria*, escrita em números.

Obrigado!

Dúvidas? Vamos julgar.
