
Realimentação de Relevância

Aula 06 — Rocchio, expansão de consulta e pseudo-feedback

Projeto Integrador III ■ Ciência de Dados

FATEC — Tecnologia em Ciência de Dados

Já temos

- Modelos: booleano, TF-IDF, BM25
- Métricas: P@k, MAP, nDCG, MRR


Hoje (fecha a Fase 2)

- Usar o **feedback** do usuário
- **Rocchio** e expansão de consulta
- *Pseudo*-realimentação

Ideia

A primeira consulta raramente é perfeita. Podemos **reformulá-la** a partir do que é relevante.

O ciclo de realimentação de relevância




O sistema aprende com poucos exemplos e **move a consulta** na direção dos bons resultados.

$$\vec{q}_m = \alpha \vec{q}_0 + \beta \frac{1}{|D_r|} \sum_{d \in D_r} \vec{d} - \gamma \frac{1}{|D_{nr}|} \sum_{d \in D_{nr}} \vec{d}$$

- Aproxima a consulta dos **relevantes** (D_r) e a afasta dos **não relevantes** (D_{nr}).
- α, β, γ pesam consulta original, feedback positivo e negativo.
- Valores comuns: $\alpha = 1$, $\beta = 0,75$, $\gamma = 0,15$.

O que significa: mover a consulta



- Consulta e documentos são **vetores** no mesmo espaço (uma dimensão por termo, pesos TF-IDF — Aula 02).
- O usuário marcou **relevantes** e **não relevantes**.
- Rocchio **empurra** $\vec{q}_0$ para o **centro** dos relevantes e a **afasta** do centro dos não relevantes.
- O resultado $\vec{q}_m$ é uma **nova consulta**: buscamos de novo com ela, pelo cosseno.

As entradas do Rocchio, uma a uma

$$\vec{q}_m = \alpha \vec{q}_0 + \beta \underbrace{\frac{1}{|D_r|} \sum_{d \in D_r} \vec{d}}_{\text{centroide dos relevantes}} - \gamma \underbrace{\frac{1}{|D_{nr}|} \sum_{d \in D_{nr}} \vec{d}}_{\text{centroide dos não relevantes}}$$

$\vec{q}_0$	consulta original : peso TF-IDF dos termos digitados; zero nos outros 42
D_r, D_{nr}	documentos marcados relevantes (aqui: d2, d3) e não relevantes (aqui: d4; pode ser vazio)
$ D_r $	quantos documentos há em D_r (aqui: 2)
$\frac{1}{ D_r } \sum \vec{d}$	a média dos vetores: o “documento relevante típico” (<i>centroide</i>)
α	quanto confiar no que foi digitado (comum: 1)
β	quanto puxar para os relevantes (comum: 0,75)
γ	quanto empurrar para longe dos não relevantes (comum: 0,15 — menor que β : saber o que <i>não</i> se quer ajuda menos)
$\vec{q}_m$	consulta modificada : pesos também em termos que ninguém digitou

Como o algoritmo é aplicado, passo a passo

- 1 **Busca inicial** com $\vec{q}_0$ (cosseno) e mostra o ranking ao usuário.
- 2 O usuário **marca** alguns resultados: relevantes (D_r) e não relevantes (D_{nr}).
- 3 Calcula o **centroide** de D_r e o de D_{nr} : média, termo a termo, das colunas da matriz TF-IDF.
- 4 **Combina**: $\alpha \vec{q}_0 + \beta \bar{d}_r - \gamma \bar{d}_{nr}$.
- 5 (opcional) **Zera os pesos negativos** — muitos sistemas fazem isso.
- 6 **Busca de novo** com $\vec{q}_m$ e mostra o novo ranking. O ciclo pode se repetir.

Uma consulta de 3 termos vira uma de 21

Na nossa consulta, $\vec{q}_m$ tem peso em **21** termos: os 3 digitados, os dos relevantes (bm25, espaco, ..., positivos) e os do não relevante (aprendizado, ..., negativos).

A conta, termo a termo

Consulta "modelo de recuperacao"; $D_r = \{d2, d3\}$, $D_{nr} = \{d4\}$; $\alpha = 1$, $\beta = 0,75$, $\gamma = 0,15$.

termo	$\vec{q}_0$	$\bar{d}_r = \frac{d2+d3}{2}$	$\bar{d}_{nr} = d4$	conta	$\vec{q}_m$
modelo	1,386	$(1,386 + 1,386)/2 = 1,386$	0	$1,386 + 0,75 \cdot 1,386 - 0$	2,426
recuperacao	1,386	0	1,386	$1,386 + 0 - 0,15 \cdot 1,386$	1,178
de	0,470	$(0,470 + 0,940)/2 = 0,705$	0	$0,470 + 0,75 \cdot 0,705$	0,999
bm25	0	$(0 + 2,079)/2 = 1,040$	0	$0 + 0,75 \cdot 1,040$	0,780
aprendizado	0	0	2,079	$0 + 0 - 0,15 \cdot 2,079$	-0,312

- modelo está na consulta e nos relevantes: **reforçado**.
- recuperacao está na consulta, mas só no não relevante: **enfraquecido**.
- bm25 ninguém digitou: **entrou** na consulta (expansão). aprendizado: peso **negativo**.

O efeito: expansão de consulta

- Termos frequentes nos documentos **relevantes** entram na consulta.
- A consulta deixa de ser 3 palavras e passa a “entender” o contexto do tema.
- Cuidado: feedback negativo em excesso pode **distorcer** a consulta.

Vamos ver na prática quais termos surgem e como o ranking muda.

Ponto de partida: ranking base (cosseno)

```
docs <- c(
  d1 = "recuperacao de informacao ordena documentos por relevancia",
  d2 = "o modelo de espaco vetorial representa documentos como vetores",
  d3 = "bm25 e um modelo probabilistico de ranqueamento de texto",
  d4 = "aprendizado estatistico fundamenta a recuperacao moderna",
  d5 = "o indice invertido acelera a busca em muitos documentos",
  d6 = "embeddings capturam a semantica de palavras e documentos",
  d7 = "a avaliacao mede a relevancia dos resultados da busca",
  d8 = "ciencia de dados combina estatistica e programacao"
)
tok    <- function(x) unlist(strsplit(tolower(x), "\\s+"))
tokens <- lapply(docs, tok)
vocab  <- sort(unique(unlist(tokens)))
tf     <- sapply(tokens, function(t) as.integer(table(factor(t, levels = vocab))))
rownames(tf) <- vocab
idf    <- log(ncol(tf) / rowSums(tf > 0))
w      <- tf * idf
cosseno <- function(a, b) sum(a*b) / (sqrt(sum(a^2)) * sqrt(sum(b^2)))
qw     <- as.integer(table(factor(tok("modelo de recuperacao"), levels = vocab))) * idf
```

Rocchio e a consulta expandida

O gabarito da Aula 05 diz: d2 e d3 têm grau 2 (relevantes). E d4, grau 0, está em 3º no ranking base: é o não relevante mais incômodo.

```
rocchio <- function(q, Dr, Dnr, a = 1, b = 0.75, g = 0.15) {  
  cr <- rowMeans(w[, Dr, drop = FALSE])  
  cnr <- rowMeans(w[, Dnr, drop = FALSE])  
  a*q + b*cr - g*cnr  
}  
qm <- rocchio(qw, Dr = c("d2", "d3"), Dnr = "d4") # segundo o gabarito  
round(sort(qm, decreasing = TRUE)[1:6], 3) # termos de maior peso
```

modelo recuperacao	de	bm25	como
2.426	1.178	0.999	0.780
espaco			
0.780			

Novo ranking após o feedback

```
novo <- apply(w, 2, function(d) cosseno(qm, d))  
round(sort(novo, decreasing = TRUE), 3)
```

d3	d2	d1	d6	d8	d5	d7	d4
0.650	0.643	0.140	0.055	0.045	0.041	-0.007	-0.060

d3 e d2 — os relevantes — vão ao **topo** (d2 sobe do 4º para o 2º); d4 (marcado não relevante) cai do 3º para o **fim**. Com pesos negativos na consulta, o cosseno pode ficar **abaixo de zero**.

Pseudo-realimentação (feedback cego)

- E quando **não há** usuário para marcar relevância?
- **Assumimos** que os *top-k* da primeira busca são relevantes.
- Aplicamos Rocchio automaticamente com esse conjunto.

Risco: *query drift*

Se os *top-k* não forem bons, a consulta expande na direção errada. Use k pequeno e β moderado.

Quando usar realimentação?

Bom para

- Consultas curtas/ambíguas
- Recall baixo na 1ª tentativa

Cuidados

- Custo de uma 2ª busca
- *Query drift*
- Usuário nem sempre dá feedback

Ideia moderna equivalente: reformular a consulta com modelos de linguagem.

Tarefa

- ① Implementar *rocchio* sobre o *corpus* de 8 documentos.
- ② Escolher uma consulta, marcar 1–2 relevantes e comparar o ranking antes/depois.
- ③ Implementar *pseudo-feedback* com os *top-2* e discutir o resultado.

Próxima fase (neural)

- Embeddings e semântica
- Recuperação densa

Leitura

- Manning et al., *IIR* — cap. 9
- Baeza-Yates & Ribeiro-Neto — cap. 5

Obrigado!

Dúvidas? Vamos ao R.
